BAB I
PENDAHULUAN

1.1 Latar Belakang

Deteksi objek merupakan salah satu tugas penting dalam computer vision yang bertujuan mengenali keberadaan objek sekaligus menentukan lokasi objek tersebut di dalam citra. Pada konteks transportasi, deteksi kendaraan dapat dimanfaatkan sebagai komponen pendukung pemantauan lalu lintas, sistem bantuan pengemudi, dan pengembangan teknologi kendaraan otonom. Kinerja deteksi yang konsisten menjadi penting karena sistem harus memproses citra jalan dengan variasi kondisi lingkungan yang tidak selalu ideal.

Salah satu faktor lingkungan yang berpotensi memengaruhi kinerja deteksi adalah kondisi pencahayaan. Citra pada siang hari umumnya memiliki penerangan yang lebih memadai, sedangkan citra pada senja atau malam hari dapat memiliki kontras lebih rendah, bayangan lebih kuat, noise, pantulan lampu, dan detail objek yang kurang jelas. Kondisi tersebut dapat membuat batas kendaraan sulit dibedakan dari latar belakang sehingga berpotensi meningkatkan kesalahan deteksi. Meskipun demikian, besar penurunan kinerja tidak dapat diasumsikan begitu saja dan perlu diukur menggunakan eksperimen yang terkontrol.

Perkembangan metode deteksi berbasis deep learning, termasuk keluarga You Only Look Once (YOLO), telah mendorong deteksi objek yang relatif cepat dengan pendekatan satu tahap. Model YOLO memprediksi kelas dan lokasi objek dalam satu proses inferensi sehingga banyak digunakan pada aplikasi yang memerlukan pemrosesan citra secara efisien [7], [8]. Namun, model yang memiliki kinerja baik pada kondisi umum belum tentu memiliki tingkat kinerja yang sama ketika diterapkan pada citra dengan pencahayaan berbeda.

Penelitian terdahulu telah mengembangkan pendekatan khusus untuk deteksi objek pada kondisi malam atau pencahayaan rendah. Yi et al. [2] mengusulkan pengembangan YOLOX dan strategi transfer domain untuk deteksi kendaraan serta pejalan kaki pada malam hari. Yin et al. [3] mengembangkan model YOLO ringan untuk deteksi kendaraan pada kondisi gelap. Qiu et al. [4] membahas deteksi pada kondisi lalu lintas berkabut dan

bercahaya rendah, sedangkan Yuan et al. [5] meneliti peningkatan deteksi kendaraan pada jam sibuk sore. Penelitian yang lebih baru, seperti YOLO-Night, juga secara khusus mengembangkan arsitektur untuk persepsi malam hari [6]. Literatur tersebut menunjukkan bahwa pencahayaan rendah merupakan tantangan yang aktif diteliti, tetapi pendekatan yang mengubah arsitektur atau menambahkan peningkatan citra tidak selalu menjawab pertanyaan dasar tentang seberapa besar perbedaan kinerja model dasar antar-kondisi pencahayaan.

Dataset BDD100K yang diperkenalkan oleh Yu et al. [1] menyediakan citra berkendara dengan keragaman kondisi lingkungan dan anotasi untuk berbagai tugas, termasuk deteksi objek jalan. Keberagaman ini membuat BDD100K relevan untuk menguji model pada kelompok kondisi waktu seperti siang, senja, dan malam, selama label kondisi dan anotasi objek yang dibutuhkan tersedia pada subset yang dipilih. Dengan menggunakan satu model dasar dan protokol evaluasi yang sama, perbedaan kinerja antarkondisi dapat dianalisis secara lebih terukur.

Berdasarkan uraian tersebut, penelitian ini mengusulkan evaluasi eksperimental terhadap kinerja model YOLO pada deteksi kendaraan di citra jalan dengan kondisi pencahayaan berbeda menggunakan dataset BDD100K. Penelitian akan memisahkan data berdasarkan kategori waktu/pencahayaan yang tercantum pada metadata dataset, membatasi kelas objek yang dianalisis pada kategori kendaraan terpilih, serta membandingkan hasil menggunakan metrik precision, recall, mAP@0.5, dan mAP@0.5:0.95. Penelitian ini tidak mengusulkan arsitektur YOLO baru, melainkan berfokus pada analisis kuantitatif dan kualitatif atas perubahan kinerja model dalam kondisi pencahayaan berbeda.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah penelitian ini adalah:

1. Bagaimana kinerja model YOLO dalam mendeteksi kendaraan pada kelompok citra siang, senja, dan malam di dataset BDD100K.
2. Seberapa besar perbedaan precision, recall, mAP@0.5, dan mAP@0.5:0.95 di antara kelompok kondisi pencahayaan.
3. Jenis kesalahan deteksi apa yang lebih sering muncul pada citra dengan pencahayaan rendah, seperti kendaraan terlewat, deteksi keliru, atau kotak pembatas yang kurang tepat.

4. Sejauh mana perbedaan distribusi jumlah objek, ukuran objek, dan karakteristik citra antarkelompok perlu dipertimbangkan saat menafsirkan hasil evaluasi.

1.3 Tujuan Penelitian

Tujuan umum penelitian ini adalah menganalisis pengaruh kondisi pencahayaan terhadap kinerja deteksi kendaraan menggunakan model YOLO pada dataset BDD100K. Tujuan khusus penelitian meliputi:

1. Mengukur kinerja model YOLO pada citra siang, senja, dan malam.
2. Membandingkan precision, recall, mAP@0.5, dan mAP@0.5:0.95 antarkelompok pencahayaan.
3. Mengidentifikasi pola kesalahan deteksi melalui pemeriksaan hasil inferensi dan confusion/error analysis yang relevan untuk deteksi objek.
4. Menyusun rekomendasi eksperimen lanjutan berdasarkan hasil evaluasi, tanpa menyimpulkan hubungan sebab-akibat di luar rancangan penelitian.

1.4 Manfaat Penelitian

Manfaat teoretis. Penelitian ini diharapkan memberikan gambaran empiris tentang variasi kinerja model deteksi kendaraan pada kelompok pencahayaan yang berbeda dengan menggunakan model dan protokol evaluasi yang sama. Hasilnya dapat menjadi dasar untuk menentukan apakah eksperimen lanjutan perlu berfokus pada augmentasi data, peningkatan citra, atau penyesuaian model.

Manfaat praktis. Hasil penelitian dapat membantu peneliti atau pengembang memahami kondisi citra yang menjadi tantangan bagi model deteksi kendaraan. Selain itu, prosedur pemilahan data, evaluasi, dan analisis kesalahan dapat dijadikan acuan untuk eksperimen computer vision yang serupa.

Manfaat bagi penelitian berikutnya. Proposal ini menyediakan rancangan eksperimen yang dapat direplikasi dan dikembangkan dengan model YOLO lain, strategi peningkatan citra, atau dataset berkendara yang berbeda.

1.5 Batasan Masalah

Agar penelitian terarah, batasan masalah ditetapkan sebagai berikut:

1. Dataset yang digunakan adalah BDD100K, khususnya subset citra yang memiliki anotasi deteksi objek dan metadata kondisi waktu/pencahayaan yang diperlukan.
2. Kategori pencahayaan mengikuti metadata dataset yang tersedia, yang direncanakan mencakup daytime, dawn/dusk, dan nighttime. Ketersediaan jumlah data dan label akan diverifikasi pada tahap eksplorasi dataset.
3. Objek yang dianalisis dibatasi pada kelas kendaraan yang didukung anotasi dataset, misalnya car, bus, truck, dan motorcycle. Kelas final ditetapkan setelah pemeriksaan format label.
4. Model dasar yang direncanakan adalah YOLOv8n dari implementasi Ultralytics. Model dan versi perangkat lunak akan dicatat agar eksperimen dapat direplikasi.
5. Fokus utama adalah evaluasi model dasar pada kelompok kondisi pencahayaan. Penelitian tidak mengusulkan modifikasi arsitektur baru dan tidak menjanjikan peningkatan kinerja sebelum eksperimen dilakukan.
6. Data pelatihan dan evaluasi mengikuti pemisahan resmi dataset sejauh label tersedia. Data evaluasi tidak digunakan dalam pelatihan atau pemilihan parameter.
7. Metrik utama adalah mAP@0.5 dan mAP@0.5:0.95; precision dan recall digunakan sebagai metrik pendukung.
8. Hasil penelitian dibatasi pada dataset dan protokol yang digunakan sehingga tidak otomatis mewakili seluruh kondisi jalan atau sistem kamera di Indonesia.

BAB II
TINJAUAN PUSTAKA

2.1 Penelitian Terkait

Penelitian deteksi objek pada citra berkendara berkembang melalui penggunaan dataset beragam dan pengembangan model deep learning. Yu et al. [1] memperkenalkan BDD100K sebagai dataset berkendara berskala besar dengan keragaman geografis, lingkungan, dan cuaca serta beragam tugas computer vision. Dataset ini mendukung penelitian yang menguji model dalam situasi jalan yang berbeda.

Pada konteks pencahayaan rendah, Yi et al. [2] mengembangkan model berbasis YOLOX dan strategi transfer domain untuk deteksi kendaraan serta pejalan kaki pada malam hari. Yin et al. [3] mengusulkan model YOLO yang lebih ringan untuk kendaraan dalam kondisi gelap. Qiu et al. [4] menggabungkan pendekatan dehazing dengan YOLOv7 untuk kondisi lalu lintas berkabut dan minim cahaya. Yuan et al. [5] mengembangkan YOLOv5-LC untuk meningkatkan deteksi kendaraan pada jam sibuk sore. Tian et al. [6] mengusulkan YOLO-Night yang secara khusus ditujukan untuk persepsi kendaraan pada malam hari.

Studi-studi tersebut relevan karena menunjukkan bahwa kondisi pencahayaan dapat menjadi tantangan khusus bagi deteksi kendaraan. Namun, sebagian penelitian berfokus pada pengembangan atau modifikasi model. Penelitian ini mengambil sudut pandang evaluasi: menggunakan satu model dasar dan protokol yang konsisten untuk membandingkan kinerja di beberapa kelompok kondisi pencahayaan. Perbedaan tersebut bukan berarti studi sebelumnya tidak menguji kondisi yang sama; posisi penelitian ini perlu dipahami sebagai analisis komparatif yang ruang lingkupnya lebih sederhana dan terukur.

Tabel 2.1 merangkum penelitian terkait dan kaitannya dengan penelitian yang diusulkan.

Peneliti	**Fokus / data**	**Metode atau kontribusi**	**Relevansi dan batasan untuk riset ini**
Yu et al. [1] (2020)	Dataset berkendara BDD100K	Dataset beragam untuk berbagai tugas visi komputer, termasuk deteksi objek jalan	Sumber dataset dan dasar pemilihan kelompok kondisi; bukan studi utama tentang efek pencahayaan pada satu model

Yi et al. [2] (2022)	Deteksi kendaraan dan pejalan kaki malam hari	YOLOX yang ditingkatkan dan strategi transfer domain	Menunjukkan tantangan malam hari; fokusnya pengembangan metode khusus
Yin et al. [3] (2024)	Deteksi kendaraan pada kondisi gelap	Model YOLO ringan dengan perubahan arsitektur	Rujukan untuk masalah low-light; berbeda dari evaluasi model dasar lintas kondisi
Qiu et al. [4] (2023)	Lalu lintas berkabut dan minim cahaya	Image dehazing dan YOLOv7	Menunjukkan kombinasi kualitas citra dan deteksi; mencakup kabut sekaligus pencahayaan
Yuan et al. [5] (2025)	Deteksi kendaraan pada jam sibuk sore	YOLOv5-LC dan strategi domain	Dekat dengan konteks sore; berfokus pada peningkatan model
Tian et al. [6] (2026)	Persepsi berkendara malam	YOLO-Night dengan komponen khusus low-light	Penelitian terbaru yang memperkuat relevansi masalah; fokus pada model khusus malam hari
Penelitian yang diusulkan	BDD100K; siang, senja, malam	Evaluasi satu model YOLO dasar dengan protokol yang sama	Mengukur dan menganalisis perbedaan kinerja serta pola kesalahan antar-kelompok pencahayaan

2.2 Landasan Teori

2.2.1 Computer Vision dan Deteksi Objek

Computer vision merupakan bidang yang mengembangkan metode agar komputer dapat memperoleh informasi dari citra atau video. Salah satu tugasnya adalah deteksi objek, yaitu menentukan kelas objek dan lokasi objek di dalam citra. Hasil deteksi umumnya direpresentasikan sebagai label kelas, skor kepercayaan, dan bounding box yang menunjukkan lokasi objek.

2.2.2 Kondisi Pencahayaan pada Citra Jalan

Kondisi pencahayaan memengaruhi intensitas piksel, kontras, keterlihatan tepi, dan detail objek. Pada malam hari, sumber cahaya dapat terbatas atau tidak merata; lampu kendaraan dan lampu jalan juga dapat menimbulkan sorotan terang yang berdampingan dengan area gelap. Senja dapat memperlihatkan transisi pencahayaan yang berubah-ubah. Faktor tersebut berpotensi memengaruhi kemampuan model dalam mengenali kendaraan. Dalam penelitian ini, kondisi pencahayaan diperlakukan sebagai variabel pengelompokan berdasarkan metadata dataset, bukan sebagai ukuran iluminansi fisik yang diukur menggunakan alat khusus.

2.2.3 Algoritma YOLO

You Only Look Once (YOLO) merupakan keluarga metode deteksi objek satu tahap yang memproses citra untuk memprediksi lokasi bounding box dan kelas objek. Pendekatan satu tahap dirancang agar proses deteksi efisien untuk penggunaan praktis. Berbagai generasi YOLO memiliki perbedaan arsitektur dan implementasi. Penelitian ini merencanakan penggunaan YOLOv8n melalui implementasi Ultralytics [8] sebagai model dasar yang relatif ringan. Karena YOLOv8 dikelola sebagai perangkat lunak dan dokumentasi oleh Ultralytics, versi paket, bobot awal, ukuran citra masukan, dan parameter inferensi akan dicatat dalam laporan.

2.2.4 Dataset BDD100K

BDD100K diperkenalkan sebagai dataset berkendara dengan variasi lokasi, lingkungan, dan kondisi cuaca, serta anotasi untuk sejumlah tugas visi komputer [1]. Untuk penelitian ini, subset deteksi objek digunakan bersama metadata waktu/pencahayaan. Tahap eksplorasi akan memeriksa format anotasi, label kategori, jumlah citra tiap kelompok, distribusi kelas kendaraan, serta ketersediaan label untuk split yang dipilih. Jika salah satu kelompok memiliki jumlah data yang sangat kecil, hal tersebut akan dilaporkan dan dipertimbangkan saat menafsirkan hasil.

2.2.5 Praproses dan Pembagian Data

Praproses meliputi pemuatan anotasi, pemetaan kelas yang relevan, pemeriksaan label tidak valid, pengelompokan citra berdasarkan metadata, dan penyesuaian format anotasi agar sesuai dengan implementasi model. Pembagian data mengikuti split resmi jika memungkinkan. Model hanya dilatih menggunakan data latih, sedangkan data validasi digunakan untuk pemantauan atau pemilihan parameter. Data evaluasi akhir tidak digunakan untuk mengubah model. Apabila split resmi tidak menyediakan label yang dibutuhkan untuk evaluasi per-kondisi, rancangan pembagian alternatif harus ditetapkan sebelum pelatihan dan didokumentasikan secara eksplisit.

2.2.6 Metrik Evaluasi Deteksi Objek

Evaluasi deteksi objek memerlukan pencocokan prediksi bounding box dengan anotasi ground truth berdasarkan ambang Intersection over Union (IoU). Precision mengukur proporsi prediksi positif yang benar, sedangkan recall mengukur proporsi objek ground truth yang berhasil ditemukan. Mean Average Precision (mAP) merangkum Average Precision lintas kelas. mAP@0.5 menggunakan ambang IoU 0,5, sedangkan mAP@0.5:0.95 merata-ratakan hasil pada beberapa ambang IoU dari 0,5 sampai 0,95. Metrik mAP@0.5:0.95 memberikan penilaian lebih ketat terhadap ketepatan lokasi bounding box. Definisi metrik harus konsisten di seluruh kelompok pencahayaan.

2.2.7 Analisis Kesalahan Deteksi

Analisis kuantitatif dilengkapi pemeriksaan contoh prediksi yang salah. Kesalahan dapat dikelompokkan secara operasional menjadi false negative (kendaraan tidak terdeteksi), false positive (prediksi kendaraan pada area yang bukan kendaraan), kesalahan kelas, dan bounding box yang tidak cukup tumpang tindih dengan anotasi. Contoh visual dipilih berdasarkan aturan yang sama antarkelompok, bukan hanya menampilkan hasil yang mendukung dugaan awal. Analisis ini membantu menjelaskan pola di balik perubahan skor metrik.

2.3 Posisi Penelitian dan Research Gap

Dari literatur yang ditelaah, beberapa penelitian mengembangkan arsitektur YOLO atau menambahkan metode peningkatan citra untuk menangani kondisi malam dan pencahayaan rendah [2]–[6]. BDD100K menyediakan konteks data berkendara yang beragam [1]. Ruang penelitian yang akan diuji dalam proposal ini adalah analisis komparatif terkontrol terhadap satu model dasar pada kelompok pencahayaan yang berbeda, dengan metrik dan protokol evaluasi yang sama, serta analisis kesalahan deteksi.

Research gap ini bersifat sementara dan dibatasi pada literatur yang berhasil ditelaah saat penyusunan proposal. Sebelum proposal final, peneliti perlu melakukan pencarian sistematis tambahan untuk memastikan apakah sudah ada studi yang melakukan evaluasi yang identik pada versi model dan subset BDD100K yang sama. Kontribusi yang ditargetkan bukan klaim bahwa penelitian pertama di bidang ini, melainkan menyediakan hasil eksperimen yang transparan dan dapat direplikasi pada ruang lingkup yang jelas.

Aspek	**Kondisi pada literatur yang ditelaah**	**Rencana penelitian ini**
Fokus	Banyak studi menekankan modifikasi model untuk kondisi malam/low-light	Mengevaluasi model dasar tanpa mengubah arsitektur
Perbandingan kondisi	Sebagian studi membatasi eksperimen pada kondisi malam atau kondisi sulit tertentu	Membandingkan siang, senja, dan malam dalam satu protokol
Metrik	Metrik deteksi digunakan untuk menguji metode yang diusulkan	Melaporkan precision, recall, mAP@0.5, dan mAP@0.5:0.95 dengan definisi yang konsisten
Analisis kesalahan	Penekanan bergantung pada fokus tiap studi	Mengelompokkan contoh kesalahan dan meninjau pola visual per kondisi
Kontribusi	Peningkatan model atau strategi penanganan low-light	Baseline komparatif yang terdokumentasi untuk mendukung eksperimen lanjutan

BAB III
METODOLOGI PENELITIAN

3.1 Jenis dan Tahapan Penelitian

Penelitian ini menggunakan pendekatan kuantitatif eksperimental. Model deteksi objek dijalankan pada dataset yang dikelompokkan menurut kondisi pencahayaan, kemudian hasil evaluasi dibandingkan secara deskriptif dan, apabila asumsi serta jumlah sampel mendukung, menggunakan analisis statistik tambahan. Penelitian tidak mengembangkan aplikasi pengguna dan tidak mengubah arsitektur model utama.

Tahapan penelitian meliputi: (1) studi literatur; (2) pengunduhan dan pemeriksaan dataset; (3) penentuan kelompok kondisi dan kelas kendaraan; (4) praproses dan validasi anotasi; (5) pelatihan atau penyiapan model dasar; (6) inferensi pada data evaluasi; (7) perhitungan metrik; (8) analisis kesalahan; serta (9) penyusunan laporan.

3.2 Dataset

Dataset utama adalah BDD100K [1]. Penggunaan dataset ini dipilih karena menyediakan citra berkendara yang bervariasi dan anotasi deteksi objek. Data yang digunakan harus berasal dari sumber resmi atau saluran distribusi yang diizinkan oleh pemilik dataset. Pada tahap awal, peneliti akan memeriksa dokumentasi dan berkas anotasi untuk memastikan ketersediaan label waktu/pencahayaan serta kelas kendaraan.

Kelompok kondisi direncanakan terdiri atas daytime, dawn/dusk, dan nighttime, sesuai metadata yang tersedia. Kelas kendaraan yang akan dipertahankan adalah car, bus, truck, dan motorcycle apabila seluruh kelas tersebut tersedia dan konsisten pada anotasi yang dipilih. Tabel 3.1 merupakan format ringkasan yang akan diisi setelah eksplorasi dataset; jumlah data tidak dicantumkan sebelum diverifikasi.

Kelompok kondisi	Jumlah citra	Jumlah objek kendaraan	Keterangan
Siang (daytime)	Diisi setelah audit dataset	Diisi setelah audit dataset	Berdasarkan metadata resmi
Senja (dawn/dusk)	Diisi setelah audit dataset	Diisi setelah audit dataset	Berdasarkan metadata resmi
Malam (nighttime)	Diisi setelah audit dataset	Diisi setelah audit dataset	Berdasarkan metadata resmi
Total	Dihitung setelah audit	Dihitung setelah audit	Dilaporkan per split dan kelas

3.3 Variabel dan Skenario Eksperimen

Variabel bebas utama adalah kelompok kondisi pencahayaan yang tercatat pada metadata dataset. Variabel terikat adalah nilai metrik deteksi kendaraan. Faktor lain seperti model, ukuran citra masukan, confidence threshold, IoU threshold untuk evaluasi, daftar kelas, dan prosedur inferensi akan dibuat konsisten sejauh dapat dikendalikan.

Skenario eksperimen utama:

1. Skenario A — evaluasi pada kelompok daytime.
2. Skenario B — evaluasi pada kelompok dawn/dusk.
3. Skenario C — evaluasi pada kelompok nighttime.

Model yang sama digunakan untuk semua kelompok. Model direncanakan dilatih menggunakan data latih resmi yang tersedia, kemudian dievaluasi terpisah pada subset validasi berlabel yang dikelompokkan berdasarkan kondisi. Dengan demikian, perbandingan terutama mengukur bagaimana model yang sama bekerja pada kondisi berbeda, bukan membandingkan tiga model yang dilatih secara berbeda. Jika distribusi data latih tidak memadai untuk salah satu kondisi, keterbatasan ini akan dijelaskan dan dapat menjadi dasar eksperimen tambahan.

3.4 Praproses Data

Langkah praproses direncanakan sebagai berikut:

1. Memeriksa kelengkapan berkas citra, anotasi bounding box, label kelas, dan metadata kondisi waktu.
2. Menghapus atau memperbaiki anotasi yang terbukti tidak valid sesuai aturan dokumentasi dataset; semua perubahan dicatat.
3. Memetakan kelas kendaraan yang dipilih ke indeks kelas model dan mengecualikan kelas di luar ruang lingkup.
4. Mengelompokkan citra evaluasi berdasarkan kategori waktu/pencahayaan dari metadata, bukan dengan penilaian subjektif setelah melihat hasil model.
5. Memastikan tidak ada citra evaluasi yang masuk ke data pelatihan.
6. Menyamakan ukuran input dan konfigurasi inferensi untuk seluruh kelompok.
7. Melakukan audit jumlah citra dan objek per kelas sebelum eksperimen.

3.5 Pemodelan

Model dasar yang direncanakan adalah YOLOv8n dari paket Ultralytics [8], dengan bobot awal pretrained yang sesuai dan dicatat versinya. Pemilihan varian n (nano) dimaksudkan agar eksperimen relatif ringan untuk lingkungan komputasi mahasiswa. Parameter awal yang direncanakan adalah ukuran citra 640 × 640 piksel; jumlah epoch dan batch size ditentukan berdasarkan kemampuan perangkat serta uji awal, lalu dibekukan sebelum evaluasi final.

Jika pelatihan ulang dilakukan, proses hanya menggunakan split training. Pemantauan training menggunakan validation set dan checkpoint terbaik dipilih berdasarkan aturan yang ditentukan sebelum pengujian akhir. Jika waktu atau sumber daya terbatas, peneliti dapat mengevaluasi bobot pretrained pada subset terkontrol, tetapi perubahan ini harus dinyatakan jelas karena pertanyaan penelitian dan interpretasi hasilnya berbeda. Seluruh versi pustaka, konfigurasi, seed, bobot, dan perangkat keras dicatat untuk mendukung replikasi.

3.6 Protokol Validasi dan Pengendalian Eksperimen

1. Menggunakan split resmi BDD100K selama label dan metadata yang dibutuhkan tersedia.
2. Menetapkan validation set sebagai data evaluasi per kondisi; tidak melakukan pelatihan pada citra tersebut.
3. Menetapkan parameter inferensi dan evaluasi yang sama pada seluruh kelompok pencahayaan.
4. Mengulang proses pelatihan dengan seed berbeda jika sumber daya memungkinkan; apabila hanya satu pelatihan dilakukan, keterbatasan variasi hasil dicatat.
5. Melaporkan jumlah citra, jumlah objek, distribusi kelas, dan metrik per kondisi agar perbedaan ukuran sampel dapat diperhatikan.
6. Tidak menyeimbangkan kelompok evaluasi dengan menghapus data secara sembarang. Jika dilakukan sampling untuk analisis tambahan, hasil sampling dilaporkan terpisah dari evaluasi utama.

3.7 Rencana Metrik Evaluasi

3.7.1 Analisis Hasil

Metrik akan dilaporkan per kelompok kondisi pencahayaan dan, jika jumlah sampel memadai, per kelas kendaraan. Selisih absolut dan relatif terhadap kelompok siang dapat dihitung untuk menggambarkan perubahan kinerja. Visualisasi berupa diagram batang atau tabel perbandingan digunakan untuk meringkas hasil. Contoh deteksi salah diperiksa untuk mengidentifikasi pola seperti objek gelap, kendaraan kecil atau jauh, silau lampu, dan oklusi. Pola tersebut akan dilaporkan sebagai observasi kualitatif, bukan sebagai penyebab pasti tanpa eksperimen tambahan.

3.8 Pertimbangan Validitas dan Ancaman terhadap Validitas

Perbedaan skor antarkelompok tidak selalu disebabkan oleh pencahayaan saja. Kelompok malam dapat berbeda dari kelompok siang dalam hal kepadatan lalu lintas, ukuran kendaraan dalam citra, jenis jalan, cuaca, dan distribusi kelas. Oleh karena itu, penelitian akan melaporkan statistik dasar per kelompok dan menafsirkan hasil sebagai hubungan antara kategori kondisi citra dan kinerja model pada dataset yang digunakan, bukan sebagai bukti sebab-akibat murni.

Ancaman lain meliputi jumlah sampel senja yang mungkin lebih kecil, ketidakseimbangan kelas, ketidakkonsistenan anotasi, serta perbedaan versi perangkat lunak. Mitigasinya adalah dokumentasi dataset, konfigurasi yang konsisten, audit anotasi, dan pelaporan keterbatasan secara eksplisit.

3.9 Pertimbangan Etika dan Lisensi

Penelitian menggunakan dataset publik untuk tujuan akademik sesuai syarat penggunaan dan lisensi yang ditetapkan pengelola. Peneliti wajib mencantumkan sitasi dataset dan tidak mencoba mengidentifikasi individu dalam citra. Jika citra menampilkan pelat kendaraan atau orang, contoh visual dalam laporan dipilih secara terbatas dan dapat diburamkan apabila diperlukan. Data tidak digunakan untuk membuat klaim tentang perilaku individu atau melakukan pelacakan identitas.

DAFTAR PUSTAKA

[1] F. Yu, H. Chen, X. Wang, W. Xian, Y. Chen, F. Liu, V. Madhavan, and T. Darrell, “BDD100K: A Diverse Driving Dataset for Heterogeneous Multitask Learning,” in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2020, pp. 2636–2645. https://doi.org/10.1109/CVPR42600.2020.00271.

[2] K. Yi, K. Luo, T. Chen, and R. Hu, “An Improved YOLOX Model and Domain Transfer Strategy for Nighttime Pedestrian and Vehicle Detection,” Applied Sciences, vol. 12, no. 23, 12476, 2022. https://doi.org/10.3390/app122312476.

[3] T. Yin, W. Chen, B. Liu, C. Li, and L. Du, “Light ‘You Only Look Once’: An Improved Lightweight Vehicle-Detection Model for Intelligent Vehicles under Dark Conditions,” Mathematics, vol. 12, no. 1, 124, 2024. https://doi.org/10.3390/math12010124.

[4] Y. Qiu, Y. Lu, Y. Wang, and H. Jiang, “IDOD-YOLOV7: Image-Dehazing YOLOV7 for Object Detection in Low-Light Foggy Traffic Environments,” Sensors, vol. 23, no. 3, 1347, 2023. https://doi.org/10.3390/s23031347.

[5] X. Yuan, Q. Chen, J. Li, S. Gong, C. Lin, and X. Hu, “YOLOv5-LC: Enhancing Vehicle Detection for Evening Rushing Hour,” Journal of Transportation Engineering, Part A: Systems, vol. 151, no. 8, 2025. https://doi.org/10.1061/JTEPBS.TEENG-8652.

[6] J. Tian, M. A. Ghaffar, and Z. Li, “YOLO-Night: Lighting the Path for Autonomous Vehicles with Robust Nighttime Perception,” Sensors, vol. 26, no. 4, 1138, 2026. https://doi.org/10.3390/s26041138.

[7] A. Bochkovskiy, C.-Y. Wang, and H.-Y. M. Liao, “YOLOv4: Optimal Speed and Accuracy of Object Detection,” arXiv:2004.10934, 2020. https://arxiv.org/abs/2004.10934.

[8] G. Jocher, A. Chaurasia, and J. Qiu, “Ultralytics YOLOv8,” software, 2023. https://github.com/ultralytics/ultralytics.

[9] T.-Y. Lin et al., “Microsoft COCO: Common Objects in Context,” in European Conference on Computer Vision (ECCV), 2014, pp. 740–755. https://doi.org/10.1007/978-3-319-10602-1_48.

[10] M. Everingham, S. M. A. Eslami, L. Van Gool, C. K. I. Williams, J. Winn, and A. Zisserman, “The Pascal Visual Object Classes Challenge: A Retrospective,” International Journal of Computer Vision, vol. 111, pp. 98–136, 2015. https://doi.org/10.1007/s11263-014-0733-5.